deep_neural_network_from_scratch

2026 年 3 月 7 日

1 分块搭建工作

1.1 前向传播过程

1.1.1 建立一层神经元

注：使用行向量 + 广播机制，即输出 $\vec{z}^T = \vec{x}^T W + \vec{b}$，这样 z 就可以包含多个 batch，变成矩阵 Z，共用一个 $\vec{b}$，因为 $\vec{b}$ **会自动进行广播**。

$$Z = XW + \vec{1}\vec{b}$$

注：$\vec{b}$ 为行向量，$\vec{1}$ 为列向量

[ ]:
```
import numpy as np
class LinearLayer:
    def __init__(self, input_dim, output_dim):
        self.input_dim = input_dim
        self.output_dim = output_dim
        self.W = np.random.randn(input_dim, output_dim)
        self.b = np.zeros(output_dim)

    def forward(self, x):
        z = x @ self.W + self.b
        return z
```

test

[9]:
```
layer=LinearLayer(3,4)
input = np.array([[2,3,4],
         [3,4,5]])
z=layer.forward(input)
```

```
print(z)
```

```
[[-4.70039951 -2.92790095  5.06622023  5.92585631]
 [-5.87292075 -4.38847719  6.75256716  7.44759927]]
```

1.1.2 建立神经元处的 ReLU 函数

将 ReLU 封装成一个对象（Class），我们就可以利用它的 **属性（Attributes）** 来保存 “历史状态”。

在前向传播 forward 时，我们把 $x > 0$ 的信息存到比如 self.mask 里；

在反向传播 backward 时，我们再把 self.mask 拿出来用。这就好比在演化的路径上留下了 “记忆节点”。

[ ]:
```
class ReLU:
    def __init__(self):
        self.mask = None

    def forward(self, z):
        self.mask = (z>0)
        return z * self.mask
```

test

[ ]:
```
relu=ReLU()
z=np.array([-1,2,3])
print(relu.forward(z))
print(relu.mask)
```

```
[0 2 3]
[False  True  True]
```

1.1.3 建立损失函数

为了给未来的 backward（反向传播）打个伏笔：

计算梯度时，我们需要用到前向传播时的预测值 $\hat{Y}$ 和真实值 Y。因此，在 forward 中，除了计算出具体的 Loss 数值外，需要把传入的 Y 和 $\hat{Y}$ 作为属性保存下来。

$$L = \frac{1}{N}\sum_{i=1}^{N}(\hat{y_i} - y_i)^2$$

[ ]:
```
class MSELoss:
    def __init__(self):
        self.y_true = None
        self.y_pred = None

    def forward(self, y_pred, y_true):
        self.y_true = y_true
        self.y_pred = y_pred
        loss = np.mean((y_pred-y_true)**2)
        return loss
```

test

[23]:
```
l=MSELoss()
y_true = np.array([[1,2,3],
            [4,5,6]])
y_pred = np.array([[2,3,4],
                [3,4,4]])
print(l.forward(y_pred, y_true))
print(y_true.size)
```

```
1.5
6
```

1.2 反向传播过程

1.2.1 梯度从损失函数出发

求出 Loss 对 $\hat{Y}$ 的偏导数

$$\frac{\partial L}{\partial \hat{Y}} = \frac{2}{N}(\hat{Y} - Y)$$

[ ]:
```
class MSELoss:
    def __init__(self):
        self.y_true = None
        self.y_pred = None

    def forward(self, y_pred, y_true):
        self.delta_y = y_pred-y_true
        loss = np.mean(self.delta_y **2)
```

```
        return loss

    def backward(self):
        grad = 2/self.delta_y.size * self.delta_y
        return grad
```

1.2.2 梯度通过 ReLU 函数

ReLU 的导数

$$\left[\frac{\partial}{\partial X}\mathrm{ReLU}(X)\right]_{ij} = \begin{cases} 1 & \text{if } X_{ij} > 0 \\ 0 & \text{if } X_{ij} \leq 0 \end{cases}$$

[ ]:
```
class ReLU:
    def __init__(self):
        self.mask = None

    def forward(self, z):
        self.mask = (z>0)
        return z * self.mask

    def backward(self, input_grad):
        return input_grad * self.mask
```

1.2.3 梯度通过一层神经元

关键：当你把反向传播的梯度 $\frac{\partial L}{\partial Z}$ 传回到 LinearLayer 时，这个层和 ReLU 不同。ReLU 只需要把力传给上一层就完事了，但 LinearLayer 必须利用这个力做三件事：1. 算出给上一层的力 $\frac{\partial L}{\partial X}$ ：好让网络更前面的层继续反向传播。

2. 算出给自己权重 W 的修正力 $\frac{\partial L}{\partial W}$ ：用来更新 W。
3. 算出给自己偏置 b 的修正力 $\frac{\partial L}{\partial \vec{b}}$ ：用来更新 $\vec{b}$。

矩阵大小：

$$Z : batch \times output$$

$$X : batch \times input$$

$$W : input \times output$$

$$\vec{b} : 1 \times output$$

$$\vec{1} : batch \times 1$$

由于 $Z = XW + \vec{1}\vec{b}$，并且需要大小匹配，故有：

$$\frac{\partial L}{\partial X} = \frac{\partial L}{\partial Z} W^T$$
$$\frac{\partial L}{\partial W} = X^T \frac{\partial L}{\partial Z}$$
$$\frac{\partial L}{\partial \vec{b}} = \vec{1}^T \frac{\partial L}{\partial Z}$$

[ ]:
```python
# test np.sum()
z=[[1,2,3],
   [4,5,6]]
print(np.sum(z, axis=0))
```

```
[5 7 9]
```

对于 $\vec{1}^T \frac{\partial L}{\partial Z}$，在 NumPy 中不需要真的去造一个全 1 的向量再相乘，而是可以直接使用张量求和函数：np.sum(z, axis=0)。这里的 axis=0 意味着沿着批次（样本）的维度把梯度全加起来，完美契合公式。

[ ]:
```python
import numpy as np
class LinearLayer:
    def __init__(self, input_dim, output_dim):
        self.input_dim = input_dim
        self.output_dim = output_dim
        self.W = np.random.randn(input_dim, output_dim)
        self.b = np.zeros(output_dim)

    def forward(self, x):
        self.x = x
        z = x @ self.W + self.b
        return z

    def backward(self, grad_z):
        grad_x = grad_z @ self.W.T
        self.grad_W = self.x.T @ grad_z
        self.grad_b = np.sum(grad_z, axis=0)
        return grad_x
```

1.2.4 神经元参数更新

刚才算出的梯度 grad_W ($\frac{\partial L}{\partial W}$)，是指向 Loss 增加最快方向的向量。

为了让 Loss 极小化，必须往**负梯度**的方向移动。

在数值计算中，我们通过一个离散的步长（标量 η ）来更新状态，这个步长是**人为设定**的，且对 W 和 $\vec{b}$ 是相同的（因为梯度自带”分配比例“）

$$W_{new} = W_{old} - \eta \frac{\partial L}{\partial W}$$
$$\vec{b}_{new} = \vec{b}_{old} - \eta \frac{\partial L}{\partial \vec{b}}$$

[ ]:
```python
import numpy as np
class LinearLayer:
    def __init__(self, input_dim, output_dim):
        self.input_dim = input_dim
        self.output_dim = output_dim
        self.W = np.random.randn(input_dim, output_dim)
        self.b = np.zeros(output_dim)
        self.x = None
        self.grad_W = None
        self.grad_b = None

    def forward(self, x):
        self.x = x
        z = x @ self.W + self.b
        return z

    def backward(self, grad_z):
        grad_x = grad_z @ self.W.T
        self.grad_W = self.x.T @ grad_z
        self.grad_b = np.sum(grad_z, axis=0)
        return grad_x

    def update(self, learning_rate):
        self.W -= learning_rate * self.grad_W
        self.b -= learning_rate * self.grad_b
```

2 开始集成为神经网络

2.1 先摆上所有零件

2.1.1 网络零件

[36]:
```
import numpy as np
class LinearLayer:
    def __init__(self, input_dim, output_dim):
        self.input_dim = input_dim
        self.output_dim = output_dim
        self.W = np.random.randn(input_dim, output_dim)
        self.b = np.zeros(output_dim)
        self.x = None
        self.grad_W = None
        self.grad_b = None

    def forward(self, x):
        self.x = x
        z = x @ self.W + self.b
        return z

    def backward(self, grad_z):
        grad_x = grad_z @ self.W.T
        self.grad_W = self.x.T @ grad_z
        self.grad_b = np.sum(grad_z, axis=0)
        return grad_x

    def update(self, learning_rate):
        self.W -= learning_rate * self.grad_W
        self.b -= learning_rate * self.grad_b

class ReLU:
    def __init__(self):
        self.mask = None

    def forward(self, z):
        self.mask = (z>0)
```

```
        return z * self.mask

    def backward(self, input_grad):
        return input_grad * self.mask

    # 为了方法名称一致以便于多态调用，加入 update 方法
    def update(self, learning_rate):
        pass
```

2.1.2 损失函数评估零件

[37]:
```
class MSELoss:
    def __init__(self):
        self.y_true = None
        self.y_pred = None

    def forward(self, y_pred, y_true):
        self.delta_y = y_pred-y_true
        loss = np.mean(self.delta_y **2)
        return loss

    def backward(self):
        grad = 2/self.delta_y.size * self.delta_y
        return grad
```

2.2 再写集成主板

外部调用应是如下形式:

```
my_components = [
    LinearLayer(input_dim=2, output_dim=4),
    ReLU(),
    LinearLayer(input_dim=4, output_dim=1)
]
my_net = NeuralNetwork(my_components)

my_loss = MSELoss()
```

```
learning_rate = 0.01

for epoch in range(100): # 实验迭代 100 次
    # --- 前向演化 ---
    y_pred = my_net.forward(X)

    # --- 能量评估 ---
    loss_value = my_loss.forward(y_pred, y_true)

    # --- 产生拉回力 (梯度起爆) ---
    grad_from_loss = my_loss.backward()

    # --- 时间反演 (误差回传) ---
    my_net.backward(grad_from_loss)

    # --- 系统参数坍缩/更新 ---
    my_net.update(learning_rate)
```

2.2.1 集成多层 LinearLayer 和 ReLU 的神经网络

[38]:
```
class NeuralNetwork:
    def __init__(self, layers):
        self.layers = layers

    def forward(self, x):
        for unit in self.layers:
            x = unit.forward(x)
        return x

    def backward(self, grad):
        for unit in self.layers[::-1]:
            grad = unit.backward(grad)
        return grad

    def update(self, learning_rate):
        for unit in self.layers:
            unit.update(learning_rate)
```

3 正式实例化

3.1 真实数据生成

[52]:
```
import numpy as np
import matplotlib.pyplot as plt
np.random.seed(42)
x_data = np.linspace(-1,1,101).reshape(-1,1) # 把行向量变为列向量，batch=100（同时观察 100 个粒子），input=1（每个粒子有 1 个自由度需要观测）
y_ideal = x_data **2
noise = 0.01 * np.random.randn(101,1)
y_true = y_ideal + noise
plt.figure(figsize=(8, 6))
plt.scatter(x_data, y_true, color='blue', alpha=0.5, s=20, label='Noisy␣
↪Observations (y_true)')
plt.plot(x_data, y_ideal, color='red', linestyle='--', linewidth=2,␣
↪label='Hidden Physics Law ($y=x^2$)')
plt.xlabel("X (Input State)")
plt.ylabel("Y (Measurement)")
plt.title("Experimental Data Setup")
plt.legend()
plt.grid(True, linestyle=':', alpha=0.6)
plt.show()
```

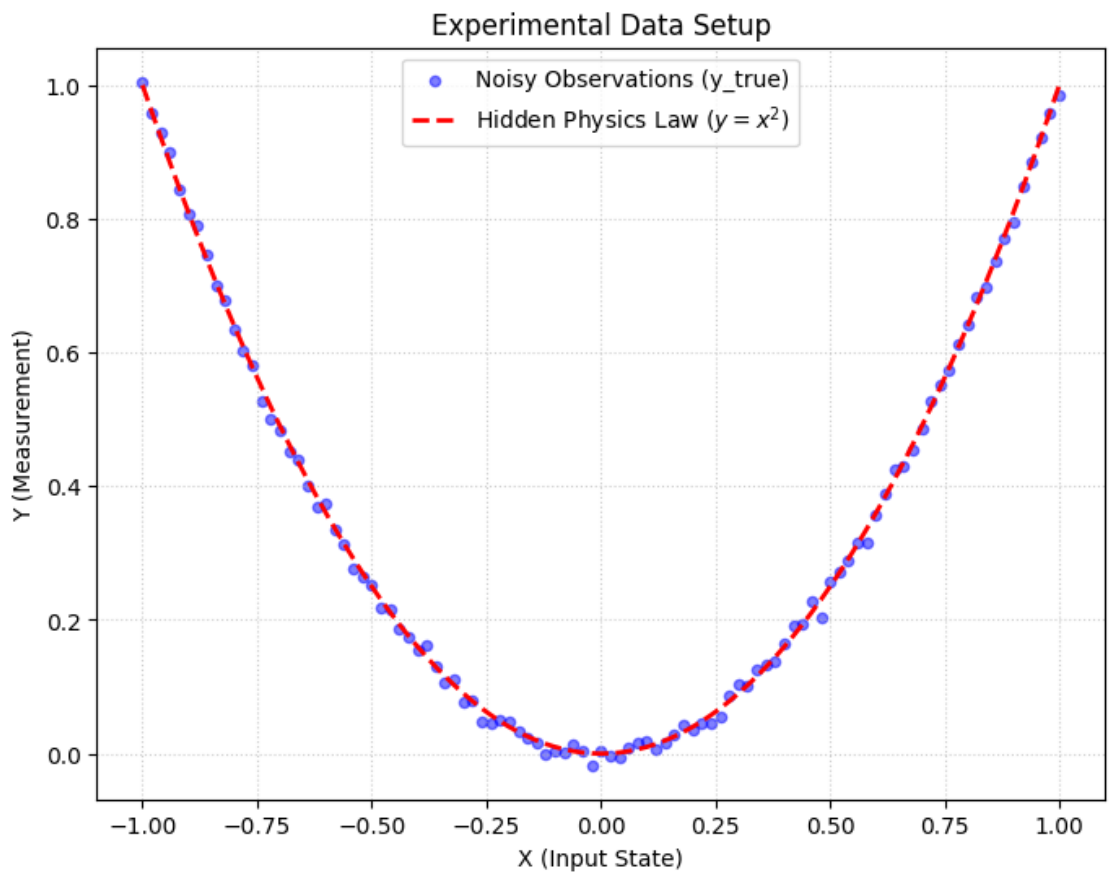

3.2 主程序

[79]:
```
layers = [LinearLayer(1, 50), ReLU(), LinearLayer(50, 10), LinearLayer(10, 1)]
my_net = NeuralNetwork(layers)
my_loss = MSELoss()
learning_rate = 0.001

for _ in range(10000):
    y_pred = my_net.forward(x_data)
    loss = my_loss.forward(y_pred, y_true)
    grad_from_loss = my_loss.backward()
    my_net.backward(grad_from_loss)
    my_net.update(learning_rate)
```

```
y_final_pred = my_net.forward(x_data)
print(loss)

plt.figure(figsize=(8, 6))
plt.scatter(x_data, y_true, color='blue', alpha=0.5, s=20, label='Noisy␣
↪Observations (y_true)')
plt.plot(x_data, y_ideal, color='red', linestyle='--', linewidth=2,␣
↪label='Hidden Physics Law ($y=x^2$)')
plt.plot(x_data, y_final_pred, color='green', linewidth=3, label='Neural␣
↪Network Prediction')
plt.xlabel("X")
plt.ylabel("Y")
plt.title("Discover Physics Law by Neural Network")
plt.legend()
plt.grid(True, linestyle=':', alpha=0.6)
plt.show()
```

```
0.00020689847950703904
```

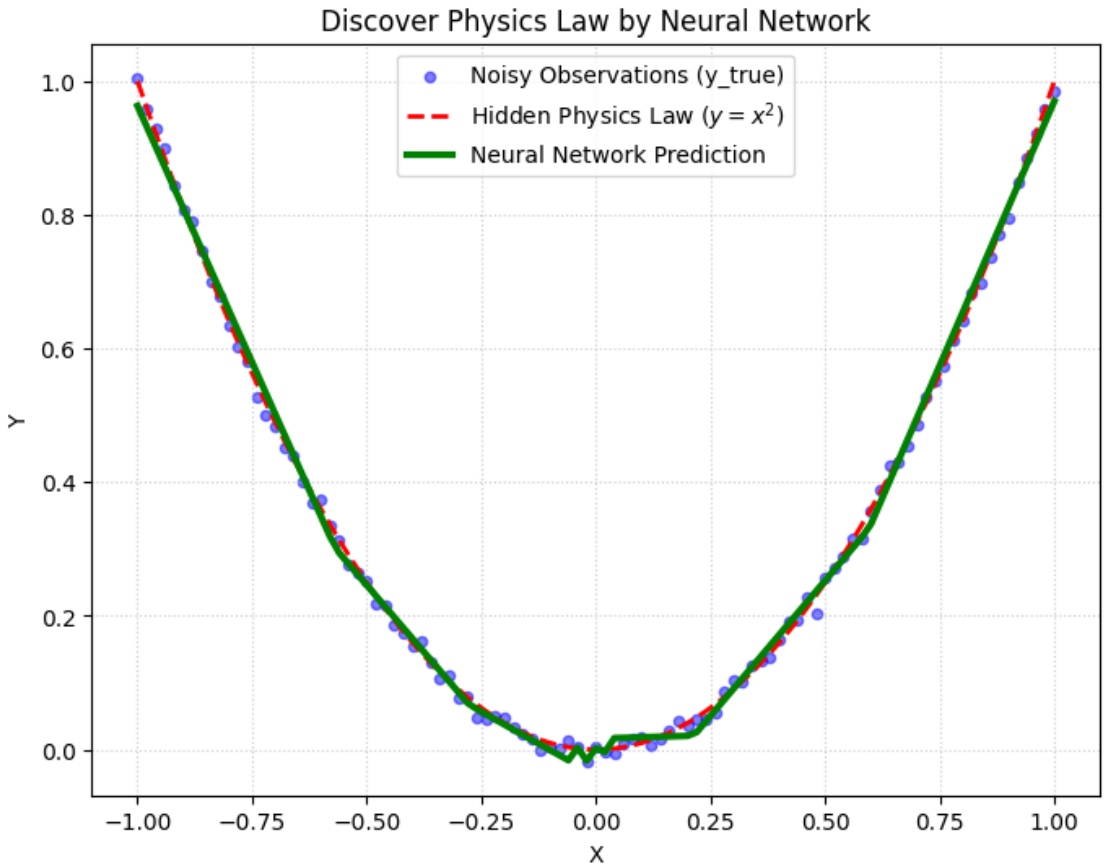
Discover Physics Law by Neural Network
Noisy Observations (y_true)
Hidden Physics Law ($y = x^2$)
Neural Network Prediction
1.0
0.8
0.6
0.4
0.2
0.0
Y
−1.00
−0.75
−0.50
−0.25
0.00
0.25
0.50
0.75
1.00
X